
KNIME HAKKINDA BİLGİLER VE ÇALIŞMALAR



ELİF ALTINBULAK
V1.7

Revizyonlar

Hazırlayan	Tarih	Stajdaki Gün	Yapılan İşlemler
Elif Altınbulak	02.01.2025	1	- Kurulumlar tamamlandı. - Dokümantasyon taslağı oluşturuldu. - KNIME nedir ve nasıl çalışır prensipleri öğrenildi. - Makine Öğrenmesi algoritmaları incelendi. - KNIME üzerinde çalışmalara başlandı. - Versiyondan dolayı bulunamayan node'lar nasıl bulunur araştırıldı ve dokümana eklendi. - Bölüm 1 tamamlandı. - KNIME üzerinden çalışmalara devam edildi. “ÇALIŞMA-1” tamamlandı. Ekstra bilgiler ve yorumlarla ilgili kısım dokümanda tamamlandı. - Bölüm 2’den devam edilecektir.
Elif Altınbulak	03.01.2025	2	- Veri Bilimi Yöntemleri öğrenildi. - Analitik Seviyeler neler ve hangi yöntemler kullanılır öğrenildi. - Bölüm 5’den devam edilecektir.
Elif Altınbulak	06.01.2025	3	- Bölüm 5 bitmiş ve Bölüm 6’dan devam edilmiştir. - Çalışma 2, 3, 4, 5 eklemiştir. - KNIME üzerinde dosya dönüştürme işlemleri tamamlanmıştır. - Bölüm 6’nın kalan kısımları, Bölüm 7 ve Bölüm 8 ‘in yarısına gelmeyi hedefliyorum.
Elif Altınbulak	07.01.2025	4	Bölüm 6 ve Bölüm 7 başarılı bir şekilde tamamlandı.

			• Çalışma 6 içerisinde önemli nodelerin kullanıldığı örnek bir proje yapıldı. • Dokümana, MetaNode yapısı, Flow Variables ve Döngülerin iyileştirilmesi alanları eklendi.
Elif Altınbulak	08.01.2025	5	• Makine öğrenmesi methodları • Overfitting • Naive Bayers yöntemi, avantajları, dezavantajları ve Naive Bayers ile ilgili çalışma • Desicion Tree yöntemi, avantajları, dezavantajları ve Desicion Tree ile ilgili çalışma • Association Rule Mining ve Algoritmaları • Bölüm 8'in çoğu tamamlandı.
Elif Altınbulak	09.01.2025	6	• Bölüm 8,9 ve 10 Başarıyla tamamlandı. Bölüm 8 içerisinde kullanılan çalışmalar da ekstra olarak yapıldı.
Elif Altınbulak	10.01.2025	7	• MAVL ve Prediction Fusion Uygulamaları • Random Forest Uygulaması • Örnek çalışmalar • Derin Öğrenme konusu tamamlandı • KNIME Eğitimi Tamamlanmıştır.

İçindekiler

KNIME ÜZERİNDE BULUNAMAYAN NODELAR	4
KNIME ÜZERİNDE KULLANILABİLECEK EKLENTİLER	6
KNIME ÜZERİNDE YAPILAN ÇALIŞMALAR	8
ÇALIŞMA – 1	8
ÇALIŞMA - 2	21

ÇALIŞMA – 3	23
ÇALIŞMA – 4	25
ÇALIŞMA - 5.....	25
Row Filter Node’u:	26
Rule – Based Row Filter Node	29
Column Filtering Node	30
Group By Node’u	30
Ungroup Node’u	30
Join ve Concatenation	31
Missing Value	31
Tarih ve Zaman Node’u	31
Table Creator ve Split Collection Node’u	32
ÇALIŞMA – 6 (Satış Verisi Analizi)	32
Veri Bilimi Yöntemleri	37
Analitik Seviyeleri	39
KNIME ÜZERİNDEN DOSYA DÖNÜŞTÜRME	40
MetaNode Yapısı	41
KNIME Değişkenleri ve Değişken Akışı (Flow Variables)	42
Döngüler (Loops) ve Model Parametrelerinin Test Edilmesi ve İyileştirilmesi	42
Makine Öğrenmesi Modelleri	42
Overfitting (Ezberleme)	42
Overfitting Önlenebilir mi?	43
Naive Bayes Yöntemi	44
Naive Bayes Hangi Verilerde Kullanılır	44
Naive Bayes'in Avantajları	45
Naive Bayes'in Dezavantajları	45
Naive Bayes Çalışması.....	45
Decision Tree Öğrenmesi	47
Decision Tree'nin Avantajları	47
Decision Tree'nin Dezavantajları	47
Decision Tree Çalışması	48
Birlikte Kural Çıkarımı (Association Rule Mining)	52
Algoritmalar	52
Kümeleme, Clustering ve K-Means Algoritmaları – Çalışması	52

K-Means Algoritması kullanımı:	53
Doğrusal (Linear) Regresyon	55
Prediction ve Linear Regression Çalışması:	55
1. K-Katlama Çapraz Doğrulama (K-Fold Cross-Validation).....	56
2. Confusion Matrix (Karmaşıklık Matrisi).....	56
3. Precision, Recall, Sensitivity, Specificity.....	57
4. Kümeleme Saflığı (Clustering Purity).....	57
KNIME Üzerinde Kullanılabilecek Diller	58
Ensemble Yöntemleri ve Meta Öğrenme Algoritmaları	58
Çalışma – MAVL ve Prediction Fusion Uygulaması.....	59
Çalışma – Random Forest Uygulaması	59
Derin Öğrenme	62

KNIME Nedir?

KNIME, veri kaynağından bir hedefe (bilgiye) veri akışı sağlamak için kullanılan güçlü bir platformdur. Bu süreç, farklı analiz ihtiyaçlarına göre çeşitlenebilir ve uyarlanabilir. KNIME ile veri hazırlama, dönüştürme, analiz ve görselleştirme gibi birçok işlem kolayca gerçekleştirilebilir.

Kullanıcı dostu arayüzü sayesinde, sürükle-bırak yöntemiyle karmaşık veri işleme işlemleri oluşturmak mümkündür. Ayrıca, geniş eklenti desteği sayesinde makine öğrenimi, veri madenciliği, görselleştirme ve büyük veri işleme gibi gelişmiş özellikler sunar. KNIME, bir "Data Mining Suite" olarak tanımlanabilir ve farklı veri kaynaklarıyla entegre olarak çalışabilir. Örneğin, Excel dosyaları, veri tabanları, büyük veri platformları ve bulut hizmetleri gibi çeşitli veri kaynaklarıyla uyumludur.

Buna ek olarak, KNIME açık kaynak kodlu bir yapıya sahiptir ve Python, R gibi popüler programlama dilleriyle entegrasyon sağlayarak kullanıcıların ihtiyaçlarına yönelik özelleştirilmiş çözümler geliştirmesine olanak tanır.

Sonuç olarak, KNIME, veri analitiği ve veri madenciliği süreçlerini optimize eden, güçlü ve esnek bir araçtır. Her seviyeden kullanıcı için erişilebilir olup, iş süreçlerinin verimli bir şekilde yönetilmesine katkı sağlar.


KNIME ÜZERİNDE BULUNAMAYAN NODELAR

KNIME üzerinde çalışırken işlemleri gerçekleştirmek için nodelara ihtiyaç duyarız. Nodelar, veri hazırlama, analiz ve görselleştirme gibi birçok işlemi kolayca yapmamıza olanak tanır

ancak bazı KNIME sürümlerinde IDE içerisinde belirli nodelara erişim sağlanamayabilir. Bu durumda:


1-Öncelikle <https://hub.knime.com/> web sitesine gidilir.

2-Arama kısmına istediğimiz nodeyi yazıyoruz. Örnek verecek olursak “Scorer” nodunu bulalım.



Görsel 1


3- Görsel 1’deki gibi istediğiniz nodeyi bulduktan sonra girilir.



Görsel 2

Görsel 2’de, ilgili nodun açıklama ve detaylı bilgilerine ulaşabilirsiniz. Bu bölüme giriş yaptıktan sonra, sağ kısımda nodun bir görseli görüntülenir. Bu görsel, nodeun işleme alınacağı kısımdır.

4- Görsel 2’de gösterilen "İşlem yapılacak olan kısım" görseli seçilip, çalışılacak alana sürüklenir. Bu şekilde, istediğiniz nodeyi iş akışınıza kolayca ekleyebilirsiniz.



Görsel 3

Görsel 3'te gösterildiği gibi, ilgili alana istediğiniz node eklenir. Bu yöntemle, KNIME üzerinde çalıştığınız versiyonda bulunmayan nodeyi dışarıdan ekleyebilir ve çalışmalarınıza kaldığınız yerden sorunsuz bir şekilde devam edebilirsiniz.

KNIME ÜZERİNDE KULLANILABİLECEK EKLENTİLER

KNIME, bir veri analizi ve iş akışı araç seti olarak geniş bir eklenti (extension) ve özellik yelpazesi sunar. KNIME içerisindeki extension'lar, belirli bir görev veya işlevsellik için araçlar sağlar ve ihtiyaçlara göre indirilebilir veya yüklenebilir. İşte KNIME içerisindeki bazı önemli extension kategorileri:

1. Veri Bağlantısı ve Entegrasyonu

- **Database Extensions:** SQL veritabanlarına bağlanmak ve sorgu çalıştırmak için.
- **Big Data Extensions:** Apache Hadoop, Spark gibi büyük veri platformlarına entegrasyon sağlar.
- **Cloud Extensions:** Amazon S3, Azure Blob Storage gibi bulut tabanlı hizmetlere erişim için.
- **File Readers/Writers:** CSV, Excel, JSON, XML gibi formatlar için.

2. Makine Öğrenimi ve Veri Analitiği

- **KNIME Machine Learning Extensions:** Sklearn, H2O gibi kütüphaneleri kullanarak modelleme araçları sağlar.
- **Text Processing:** Metin analizi ve doğal dil işleme (NLP) araçları.
- **Image Processing:** Görüntü analizi ve işleme araçları.

- **Time Series:** Zaman serisi analizi için özel düğümler.

3. İleri Analitik

- **KNIME Deep Learning Extensions:** TensorFlow, Keras veya PyTorch ile derin öğrenme modelleri oluşturma.
- **Statistics Extensions:** İstatistiksel analiz araçları.
- **Chemistry Extensions:** Kimyasal veri analizi ve işleme araçları.

4. Raporlama ve Görselleştirme

- **KNIME Reporting:** BIRT tabanlı raporlama araçları.
- **Plotly ve Tableau Extensions:** Veri görselleştirme ve Tableau ile entegrasyon.
- **Jupyter Notebook Integration:** Jupyter Notebook'u doğrudan KNIME'da kullanma.

5. Script ve Programlama

- **Python Integration:** Python ile düğümler oluşturma veya script yazma.
- **R Integration:** R diliyle entegrasyon.
- **Java Snippets:** Java kodu ile özelleştirilmiş düğümler yazma.

6. İş Akışı Yönetimi

- **KNIME Server Extensions:** KNIME iş akışlarını merkezi bir sunucu üzerinde çalıştırma ve yönetme.
- **Automation and Scheduling:** İş akışı otomasyonu ve zamanlama.
- **Version Control:** SVN, Git gibi sürüm kontrol araçlarıyla entegrasyon.

7. Uzmanlaşmış Alanlar

- **KNIME for Life Sciences:** Biyoenformatik ve yaşam bilimleri için.
- **KNIME IoT Extensions:** IoT cihazlarından veri alımı ve analizi.
- **KNIME Financial Extensions:** Finansal analiz ve modelleme.

Bu extension'lar, **KNIME Hub** üzerinden keşfedilebilir ve yüklenebilir. Hangi işlevlerin kullanılabilir olduğunu görmek için KNIME Analytics Platform'un eklenti yükleyicisini (**KNIME Explorer > Install KNIME Extensions**) kullanabilirsiniz. İhtiyacınıza göre doğru extension'ları seçmek için iş akışınızın ihtiyaçlarını göz önünde bulundurabilirsiniz.

KNIME ÜZERİNDE YAPILAN ÇALIŞMALAR

ÇALIŞMA – 1

Çalışma Konusu: Boy ve kilo verileri kullanılarak kişilerin cinsiyetini tahmin edebilen bir makine öğrenimi modeli geliştirilmesi.

- 1- Kullanılacak veri seti hazırlanır. Bu veri seti Excel üzerinde oluşturulabilir. Gerçek verilerden oluşturulan bir veri seti, daha doğru ve güvenilir sonuçlar elde etmenize olanak sağlar.


BOY	KİLO	CİNSİYET
185	85	Erkek
174	65	Kadın
180	95	Kadın
168	58	Kadın
175	80	Erkek
170	70	Erkek
169	75	Erkek
183	74	Erkek
180	80	Erkek
170	60	Kadın
162	97	Erkek
160	82	Erkek
171	72	Kadın
172	87	Kadın
162	73	Kadın
170	74	Kadın
175	77	Kadın
180	85	Kadın
170	75	Kadın
183	88	Erkek

Tablo 1

Tablo 1'de kullanılan veriler, "Her Seviyeye Uygun Uçtan Uca Veri Bilimi, KNIME ile" eğitiminden referans alınmış ve üzerine eklemeler yapılarak oluşturulmuştur.


- 2- Tablo 1'de oluşturulan veriler, KNIME kullanılarak işlenir. İlk olarak, "Excel Reader" node'u kullanılarak işlenecek veri sisteme yüklenir.

2.1. – “Excel Reader” node'una sağ tıklanarak “Configure” sekmesine girilir ve ilgili ayar menüsü açılır.



Görsel 4

2.2. – “Configure” sayfası üzerinden ilgili excel dosyası Görsel 5’teki gibi eklenir. Ayrıca node üzerinden birçok ayarlamayı da bu sayfa üzerinden kolaylıkla yapılabiliriz.




Görsel 5

NOT: Node'un işleme hazır olduğunu, altındaki sarı ışıktan anlayabilirsiniz. Node'un üstündeki “Run” tuşuna bastığınızda, node'un çalıştığını ve verilerin işlendiğini gözlemleyebilirsiniz. Eğer kırmızı ışık ile karşılaşırsanız, bu durum node'un içinin boş olduğunu veya ilgili veride bir hata bulunduğunu gösterebilir.



2.3- İşlenen veriler sistem içerisinde incelenebilir. *Görsel 6'da* gösterildiği gibi, adımları takip ederek ilgili verilere ulaşabilirsiniz.



Görsel 6

Görsel 6'da izlenen sıra şu şekildedir: İlgili node'a sağ tıklayın → **Open Output Port** → **Table**.


File Table (Table)					
Rows: 20 Columns: 3					
☐	#	RowID	BOY Number (integer)	☐ KİLO Number (integer)	☐ CİNSİYET String
☐	1	Row0	185	85	Erkek
☐	2	Row1	174	65	Kadın
☐	3	Row2	180	95	Kadın
☐	4	Row3	168	58	Kadın
☐	5	Row4	175	80	Erkek
☐	6	Row5	170	70	Erkek
☐	7	Row6	169	75	Erkek
☐	8	Row7	183	74	Erkek
☐	9	Row8	180	80	Erkek
☐	10	Row9	170	60	Kadın
☐	11	Row...	162	97	Erkek
☐	12	Row...	160	82	Erkek
☐	13	Row...	171	72	Kadın
☐	14	Row...	172	87	Kadın
☐	15	Row...	162	73	Kadın
☐	16	Row...	170	74	Kadın
☐	17	Row...	175	77	Kadın
☐	18	Row...	180	85	Kadın
☐	19	Row...	170	75	Kadın
☐	20	Row...	183	88	Erkek

Görsel 7

NOT: Kullandığınız KNIME sürümüne bağlı olarak, *Görsel 7*’nin ayarlanması farklılık gösterebilir. Benim kullandığım sürüm, ilk satırı otomatik olarak başlık satırı olarak algılamaktadır. Ancak, daha eski bir sürüm kullanıyorsanız, ilk satırın başlık satırı olduğunu belirtmeniz gerekebilir. Bu ayar, *Görsel 4*’te gösterildiği gibi, açılan “Configuration” sekmesi içerisinden yapılmalıdır.


Excel verisinde eksik bir veri (Missing Value) bulunması durumunda, çalışma başarısız olabilir. Bu sorunu gidermek için eksik veriler tahmin yoluyla doldurulabilir veya görmezden gelme gibi işlemlerle göz ardı edilebilir. Bu yöntemler, eksik veri problemini çözmek için etkili bir yaklaşım sağlar.

- İlgili verinin istatistiksel olarak incelenmesi, ilerleyen aşamalarda önemli bir adım olacaktır. Bu işlem için “Statistics” node’u kullanılabilir. Ayrıca, verinin istatistiklerini görselleştirmek amacıyla “Scatter Plot” node’u tercih edilebilir. Bu analizlerin sonucunda, veriye ilişkin bir karar alınarak, makine öğrenimi işlemleri bu doğrultuda gerçekleştirilecektir.



Görsel 8


Görsel 8'de, node'lar birbirine bağlanarak çalıştırılır.




Görsel 9

Görsel 7'deki verinin istatistiksel olarak incelendiğini Görsel 9'da gözlemleyebiliriz. Bu görsel incelendiğinde, minimum değer, ortalama, ortanca değer, maksimum değer, standart sapmalar gibi temel istatistiksel özet bilgileri elde edebiliriz. Ayrıca, çarpıklık (skewness) ve basıklık (kurtosis) değerleri ile verinin dağılım özellikleri değerlendirilebilir. Eksik veri sayısı ve histogram görselleri sayesinde, verinin dağılımı ve genel yapısı hakkında daha detaylı bilgi edinilebilir. Bu bilgiler, veriyi analiz etmek ve sonraki işlemler için uygun kararlar almak adına kritik bir öneme sahiptir.

Bu görsel, istatistiksel verilere dayalı olarak cinsiyet tahmininde kullanılabilecek belirli ipuçları sağlayabilir, ancak tek başına kesin bir tahmin yapmayı mümkün kılmaz. Bu nedenle, veriler “Scatter Plot” node'u kullanılarak daha detaylı bir şekilde incelenmelidir.



Görsel 10



Görsel 11

Görsel 10 ve Görsel 11 incelendiğinde daha net bir tespit yapılabilir. Bu tespit şu şekilde olabilir.

- Kadınlar için: Boy ≤ 170 cm ve Kilo ≤ 65 kg
- Erkekler için: Boy > 170 cm ve Kilo > 65 kg


İstisnalar mevcuttur.

Bu adımın temel amacı, veriyi tanımak, analiz etmek ve doğru varsayımlarla makineyi etkili bir şekilde eğitebilmektir.

4- Makinenin eğitilebilmesi için **iki tür veriye** ihtiyaç vardır:

- **Eğitim Verisi:** Modelin öğrenmesi için kullanılan veri.
- **Test Verisi:** Modelin doğruluğunu ve performansını değerlendirmek için kullanılan veri.

Bu işlemi ayarlamak için KNIME büyük bir kolaylık sağlar. KNIME'in "*Partitioning*" node'u sayesinde veriler, belirli ayarlamalarla kolayca **eğitim** ve **test** seti olarak bölünebilir.




Görsel 12

İlgili node'lar birbirine bağlandıktan sonra, "Partitioning" node'unda "Configure" sekmesine girilerek gerekli ayarlamalar yapılır. "Partitioning" node'unda ilk üçgen "**Eğitim**" ikinci üçgen ise "**Test**" anlamına gelmektedir.

Veriler sırası bozulmadan işlenir ve sırayla alınır. Ayrıca, verilerin karışık halde olması durumunda da doğru şekilde çalışacaktır.

Veriler, atlamalı bir şekilde test ve eğitim datası olarak ayrılır.

Verilen etikete göre (Cinsiyet gibi) eşit oranlarda Eğitim ve Test olarak ayırır.



Bu aşamada, veriler belirli bir oranla ayrılır. Örneğin, 200 adet veri varsa, ilk 100 veri eğitim seti, sonraki 100 veri ise test seti olarak ayrılabilir.

Bu aşamada, veri yüzdelik olarak ayarlanarak ikiye bölünür. Bölünen veriler, belirlenen yüzdelik dilime göre test veya eğitim verisi olarak kullanılacaktır.

Verilen yüzdeye göre rasgele ayıracaktır. Her çalıştırıldığında farklı eğitim ve test kümeleri oluşturur.


Görsel 13

Görsel 13'te yer alan bilgiler oldukça önemlidir. Bu aşama dikkatli ve bilinçli bir şekilde doldurulmalıdır, aksi takdirde makinenin eğitilmesi süreci istenilen sonuçları veremeyebilir.

Kendi verimi ilgili node ile ayırırken seçtiğim seçenekler şu şekildedir:

- Relative: %66
- Stratified Sampling – Etiket: Cinsiyet

4.1- İlgili node incelenir.



First Partition incelendiğinde,

RowID	BOY Number (integer)	✓ KİLO Number (integer)	✓ CİNSİYET String
Row0	185	85	Erkek
Row1	174	65	Kadın
Row4	175	80	Erkek
Row5	170	70	Erkek
Row6	169	75	Erkek
Row7	183	74	Erkek
Row9	170	60	Kadın
Row10	162	97	Erkek
Row12	171	72	Kadın
Row14	162	73	Kadın
Row15	170	74	Kadın
Row17	180	85	Kadın
Row18	170	75	Kadın

Görsel 14

Row2, Row3, Row8 gibi ifadelerin olmadığını gözlemleyebiliriz. Yani kendi aralarında istediğimiz koşullarda ayrılmışlardır.

Second Partition incelendiğinde,

RowID	BOY Number (integer)	✓ KİLO Number (integer)	✓ CİNSİYET String
Row2	180	95	Kadın
Row3	168	58	Kadın
Row8	180	80	Erkek
Row11	160	82	Erkek
Row13	172	87	Kadın
Row16	175	77	Kadın
Row19	183	88	Erkek

Görsel 15

Row2, Row3, Row8 gibi ifadelerin bu kısımda olduğunu gözlemleyebiliriz.

- 5- Bu aşamalardan sonra, makineyi eğitmek için uygun bir makine öğrenimi algoritmasının seçilmesi gerekmektedir. Bu algoritmalar genel olarak şunlardır:

Denetimli Öğrenme (Supervised Learning) Algoritmaları:

- 1- **Logistic Regression:** İkili sınıflandırma problemleri için kullanılır (örneğin, cinsiyet tahmini).
- 2- **Support Vector Machines (SVM):** Sınıflar arasında maksimum sınır oluşturur.
- 3- **k-Nearest Neighbors (k-NN):** Veri noktalarını yakın komşularına göre sınıflandırır.
- 4- **Decision Tree:** Veriyi karar düğümleriyle sınıflandırır.
- 5- **Random Forest:** Birden fazla karar ağacının birleşimi ile daha güçlü tahminler yapar.
- 6- **Gradient Boosting (XGBoost, LightGBM, CatBoost):** Tahmin doğruluğunu artırmak için hataları iteratif olarak düzeltir.

Denetimsiz Öğrenme (Unsupervised Learning) Algoritmaları:

- 1- **K-Means Clustering:** Veriyi benzerliklerine göre kümelere ayırır.
- 2- **Hierarchical Clustering:** Hiyerarşik bir yapı ile veri kümeleri oluşturur.
- 3- **Principal Component Analysis (PCA):** Veri boyutunu azaltarak analiz yapar.

Derin Öğrenme Algoritmaları:

- 1- **Artificial Neural Networks (ANN):** Daha karmaşık veri setleri için katmanlı yapıya sahiptir.
- 2- **Convolutional Neural Networks (CNN):** Görsel veri analizi için uygundur.
- 3- **Recurrent Neural Networks (RNN):** Sıralı veriler üzerinde çalışır (örneğin, zaman serisi analizleri).


Özelleştirilmiş Algoritmalar:

- 1- **Naive Bayes:** Özellikle metin sınıflandırma ve tahmin problemlerinde kullanılır.
- 2- **Linear Discriminant Analysis (LDA):** Sınıflandırma için veriyi lineer ayırır.
- 3- **Quadratic Discriminant Analysis (QDA):** LDA'nın daha karmaşık bir versiyonu.

İlerleyen aşamalarda bu algoritmalar daha detaylı bir şekilde incelenecektir.

Bu Çalışma içerisinde **“Decision Tree” Algoritması** kullanılacaktır.

KNIME içerisinde “Decision Tree” iki adet node’dan oluşmaktadır. İlk node, “Decision Tree Learner” ikinci node, “Decision Tree Predictor”. “Decision Tree Learner” node’u ilk eğitim için olan üçgene bağlanır. İkinci node ise test için olan üçgene bağlanır. Ardından “Decision Tree Learner” ve “Decision Tree Predictor” node’ları karelerden birbirlerine bağlanır. Böylece model eğitilmesini de tamamlanmış olur.



Görsel 16

Görsel 16’ da “Decision Tree” algoritması kullanılarak makine eğitilmiştir.

Verinin doğruluğuna bakabilmek için




Table incelendiğinde:

RowID	BOY Number (integer)	KİLO Number (integer)	CİNSİYET String	Prediction (CİNSİYET) String
Row2	180	95	Kadın	Kadın
Row3	168	58	Kadın	Kadın
Row8	180	80	Erkek	Kadın
Row11	160	82	Erkek	Erkek
Row13	172	87	Kadın	Kadın
Row16	175	77	Kadın	Kadın
Row19	183	88	Erkek	Erkek

Görsel 17


Görsel 17 incelendiğinde tahminlerin çoğunun tuttuğu gözlemlenebilir. Sadece Row8'in doğru bir sonuç vermediğini gözlemleriz.

Boy $\leq 181,5$: Bu dalda toplam **11 veri** var.

- Kadın ağırlıklı bir grup (%63,6 kadın, %36,4 erkek).

Boy $> 181,5$: Bu dalda toplam **2 veri** var.

- Bu gruptaki tüm bireyler erkek (%100 erkek, %0 kadın).



Kilo $\leq 74,5$: Bu dalda toplam **6 veri** var.

- Kadın ağırlıklı bir grup (%83,3 kadın, %16,7 erkek).

Kilo $> 74,5$: Bu dalda toplam **5 veri** var.

- Erkek ağırlıklı bir grup (%60 erkek, %40 kadın).

Boy $\leq 169,5$: Bu dalda toplam **2 veri** var.

- Bu gruptaki tüm bireyler erkek (%100 erkek, %0 kadın).


Boy $> 169,5$: Bu dalda toplam **3 veri** var.

- Kadın ağırlıklı bir grup (%66,7 kadın, %33,3 erkek).

Görsel 18

Görsel 18’de verilen bilgiler, Görsel 10 ve Görsel 11’de yapılan tahminlerle uyumlu olduğu görülmektedir. Görsel 10 ve Görsel 11’de boy ve kilo verileri analiz edilerek cinsiyet tahmini yapılmıştı. Görsel 18’de ise, makine öğrenmesi algoritması bu tahmin sürecini otomatize etmiş ve verilerden öğrenerek benzer kararları almıştır.

Bu durum, makine öğrenmesinin temel amacını net bir şekilde ortaya koymaktadır: Veriyi analiz ederek, belirli bir mantık çerçevesinde sonuçları otomatik olarak tahmin etmek. Böylece, önceki manuel değerlendirmelerle yapılan tahminler, makine öğrenmesi modeli tarafından daha sistematik ve hızlı bir şekilde gerçekleştirilmiştir.



Görsel 19


Görsel 19, Çalışma-1 aşamalı olarak özetlemiştir.

KNIME üzerinden oluşturduğunuz projeleri mutlaka kaydetmeyi unutmayınız.

ÇALIŞMA - 2


Çalışma Konusu: Boy ve kilo verilerini kullanarak, veri analizi ve görselleştirme işlemleri için farklı KNIME nodelerini deneme ve değerlendirme.

Öncelikle elimizde kullanacağımız veri “Excel Reader” nodu’na eklenir ve gerekli işlemler için “Color Manager” nodu ile birleştirilir.




Görsel 20

Görsel 20’de görüldüğü gibi birleştirilir ve “Color Manager” nodu içerisindeki “Configuration” kısmına girilir.




Görsel 21

Görsel 21’de kullanılan verinin kolonlarına göre analizler yapılabilir. “Nominal” kısmında yer alır bunun sebebi **iki türlü cins** olduğu için



Görsel 22

Görsel 22’de kullanılan verinin “Kilo” kolonun analizi yapılabilir. Belirli kilo aralıklarında olduğu için “Range” kısmında yer almaktadır.



Görsel 23


Görsel 23’de kullanılan verinin “Boy” kolonun analizi yapılabilir. Belirli boy aralıklarında olduğu için “Range” kısmında yer almaktadır.

Bu ayarlamalar yapıldıktan sonra ayarlamaların nasıl olduğu anlayabilmek için “Scatter Plot” nodu’nu kullanılır.



Görsel 24

Görsel 24 içerisinde işlemler tamamlanmıştır.



Görsel 25


Görsel 25'te erkekleri göstermektedir.

Verinin görselleştirilmesi verinin analizi konusunda bize oldukça kolaylık sağlamaktadır.

ÇALIŞMA – 3


Çalışma Konusu: Verinin analizi konusunda KNIME üzerinden “Scatter Matrix” node’u nedir ve ne şekilde kullanılır.

Scatter Matrix node'u, veriler üzerinde bir matris oluşturarak, veri setindeki kolonların birbirleriyle karşılaştırılmasını sağlar. Bu node, kolonlar arasındaki ilişkileri görselleştirmek ve veri analizi yapmak için kullanılır.



Görsel 26

İlgili node'ler birbirleri ile bağlanır ve sonuç incelenir.




Görsel 27

Görsel 27'de, mevcut veri setindeki kolonlar kullanılarak tüm olası matrisler oluşturulmakta ve çıkarılmaktadır. Bu işlem, kolonlar arasındaki ilişkilerin detaylı bir şekilde incelenmesi ve görselleştirilmesi için yapılır.

Aynı şekilde matrix işlemi gerçekleştikten sonra “Color Manager” node’yla da renklendirildikten sonra incelenebilir.

ÇALIŞMA – 4

Çalışma Konusu: Verilerin “Histogram” üzerinden görselleştirilmesi




Görsel 28

Görsel 28 incelendiğinde “Histogram” node’si üzerinden bakılarak incelenir.

ÇALIŞMA - 5

Çalışma Konusu: Veri üzerinde yapılan işlemlerin tek tek açıklanması ve anlaşılması.

Öncelikle, veri “Excel Reader” node’u üzerinden “Configuration” alanı kullanılarak verinin düzenlenme işlemi yapılır.




Görsel 29

Görsel 29'da, **Excel Reader** node'u kullanılarak, "Configuration" sekmesi üzerinden çeşitli filtreleme yöntemleri uygulanabilir. Örnekte gösterildiği gibi, bu işlem bir filtreleme örneği olarak değerlendirilebilir.

Bu yöntemler dışında da KNIME üzerinden Filtreleme yapılabilmesi için bazı node'lar da mevcuttur.


Row Filter Node'u:

"Row Filter" node'u KNIME üzerinde satırdaki belirli başlı filtreleme yöntemini kullanma anlamına gelmektedir. İlgili node'nin "Configuration" alanına bakıldığında belirli ayarlamaların yapılması kesinlikle gerekmektedir. Aksi takdirde veri hatalı işlenebilir ve çalışmalar hataya sebebiyet verebilir.



Görsel 30

Görsel 30 incelendiğinde “Configuration” sekmesine girilir.



Dialog - 4:2 - Row Filter

File

Filter Criteria | **Flow Variables** | **Job Manager Selection** | **Memory Policy**

Column value matching

Column to test: **CİNSİYET**

☐ filter based on collection elements

Matching criteria

☒ use pattern matching

☐ regular expression

☐ use range checking

lower bound:

upper bound:

☐ only missing values match

Enter valid pattern

Include rows by attribute value

☒ Include rows by attribute value

☐ Exclude rows by attribute value

☐ Include rows by number

☐ Exclude rows by number

☐ Include rows by RowID

☐ Exclude rows by RowID

Var olan verinin içerisindeki tüm kolonlar bu kısımda mevcuttur. Mevcut olan kolonlardan filtreleme yapılacağı kolon seçilir.

"Cinsiyet" kolonu seçildiğinde, bu kolondaki tüm değerler listelenir ve analiz için kullanılabilir. "Kadın" seçilmesi halinde verideki tüm "Kadın" cinsiyeti filtelenmiş olacaktır.

Kullanılan veri sayısal bir veri ise bu kısımda aşağı ve yukarı sınır belirlenerek bir filtreleme işlemi gerçekleştirilebilir.

İlgili kısmın seçilmesi halinde "Missing Value" olanların tespiti için kullanılır ve o kısım filtelenir.

Görsel 31

Görsel 31 gibi çalıştırıldığında çıkan veriyi gözlemleyebiliriz.

#	RowID	BOY Number (integer) ✓	KİLO Number (intege... ✓	CİNSİYET String
1	Row1	174	65	Kadın
2	Row2	180	95	Kadın
3	Row3	168	58	Kadın
4	Row9	170	60	Kadın
5	Row12	171	72	Kadın
6	Row13	172	87	Kadın
7	Row14	162	73	Kadın
8	Row15	170	74	Kadın
9	Row16	175	77	Kadın
10	Row17	180	85	Kadın
11	Row18	170	75	Kadın

Görsel 32


Görsel 32’de görüldüğü gibi basit bir filtreleme işlemi ile satır içerisindeki tüm “Kadın”ların verisi getirilmiş oldu.

Veri analizi sırasında bilgi kalabalığı, eksik veriler veya gereksiz veriler gibi sorunlarla karşılaşılabilir. Bu tür durumlarda, etkili bir analiz yapmak için verilerin dikkatlice incelenmesi gerekir. Bu sorunların üstesinden gelmek için filtreleme yöntemleri kullanılabilir. Her ne kadar her durumda en etkili çözüm olmasa da, filtreleme yöntemleri değerlendirilebilecek bir seçenektir.

Örneğin, bir veri setinde eksik kilo veya boy değerleri bulunuyorsa, bu tür veriler:


1. **Filtrelenebilir:** Eksik değerler içeren satırlar temizlenebilir.
2. **Tahmin Edilebilir:** Eksik değerler, istatistiksel veya makine öğrenimi yöntemleriyle tahmin edilebilir.

Üst üste filtreleme işlemleri yapılabilir.



Rule – Based Row Filter Node

Bu node kullanılırken belirli kurallarak yazılarak daha spesifik kuralların yazılmasını sağlayacaktır.




Görsel 33

İlgili node bağlantısı yapıldıktan sonra "Expression" kısmına ilgili filtrelenecek kod yazılır. Kod yazılırken ilgili sütunu alırken mutlaka dikkat ediniz hata ile karşılaşılabilir.

Column Filtering Node

Kolon filtreleme, veri setinden yalnızca gerekli olan kolonları seçmek veya gereksiz kolonları hariç tutmak için kullanılır. Veri boyutunu küçültmek ve sadece analiz için gerekli kolonları elde etmektir. Eksik veya gürültülü değerleri temizlemek, veri setindeki gereksiz kolonları çıkarmak.

Eksik kolonları silmek yerine, eksik değerlerin tahmin edilmesi daha verimli olabilir. Bu işlem, eksik değerlerin modele dayalı olarak doldurulmasını sağlayabilir.



Filtrelemeye dahil edilmeyen kısımlar bu kısımda yer alır

Çeşitli ayarlamalar bu kısımdan gerçekleştirilebilir.

Filtrelemeye dahil edilen kısımlar bu kısımda yer alır

Group By Node'u

Gruplama işlemleri, veri setindeki belirli bir kategoriye göre özetleme yapar. Örneğin:

- Kadın ve erkeklerin ortalama boy ve kilo değerlerini hesaplayabilirsiniz.
- Şube bazında toplam satış miktarını gruplayabilirsiniz.

Ungroup Node'u

Gruplanmış verileri eski haline döndürmek için kullanılır.


Örnek Kullanımlar

- Verileri kategoriye göre sıralamak.
- Etikete göre toplam, ortalama veya maksimum/minimum gibi değerler hesaplamak.
- Veri sıralama ve etiketleme işlemleri.


Join ve Concatenation

İki farklı veri setini birleştirmek için kullanılır. Örneğin, müşteri bilgileri ve satış bilgilerini ortak bir "CustomerID" alanına göre birleştirebilirsiniz.

- **Inner Join:** Sadece her iki veri setinde de ortak olan verileri getirir.



- **Full Outer Join:** Her iki veri setindeki tüm verileri getirir (eksik veriler null olarak doldurulur).



Concatenation, Veri setlerini üst üste ekler. Örneğin, farklı yıllara ait satış verilerini birleştirmek için kullanabilirsiniz.

Missing Value

Eksik veriler genellikle veri analizi ve makine öğrenimi süreçlerini olumsuz etkiler. KNIME, bu tür eksik verileri ele almak için birden fazla yöntem sunar:

- **Missing Value Düğümü:** Eksik değerleri doldurmak veya çıkarmak için kullanılır.
- **Tahmin Etme:** Eksik değerleri tahmin ederek doldurma işlemi yapılabilir.
- **Filtreleme:** Eksik değer içeren satırları çıkarmak.

İdeal Yöntem Eksik verileri direkt çıkarmak yerine, eksik verilerin model yardımıyla tahmin edilip doldurulması, daha güvenilir sonuçlar verir.

Tarih ve Zaman Node'u

Tarih ve zaman işlemleri, veri analizinde sıklıkla kullanılan işlemlerdir:

- **Tarih Formatlama:** Tarih değerlerini farklı formatlara dönüştürmek.
- **Tarih Farkı Hesaplama:** İki tarih arasındaki farkı gün, ay veya yıl cinsinden hesaplamak.
- **Zaman Dilimi Ayarlama:** Verileri belirli bir zaman dilimine göre düzenlemek.

Table Creator ve Split Collection Node'u

Table Creator: Manuel olarak tablo oluşturmak için kullanılır.

Split Collection Column: Birleştirilmiş kolonları ayırmak için kullanılır. Örneğin, bir kolon içinde virgülle ayrılmış birden fazla değer varsa, bunları ayrı kolonlara bölebilirsiniz.

ÇALIŞMA – 6 (Satış Verisi Analizi)

Çalışma Konusu: KNIME üzerindeki node'ları kullanarak etkinlik yapmak

Satış Verisi Analizi

Bir e-ticaret platformundan alınan satış verilerini analiz edeceksiniz. Bu analizde:

1. Satış verilerini filtreleyeceksiniz (örneğin, belirli bir kategoriye ait ürünler).
2. Eksik veri içeren satırları dolduracak veya temizleyeceksiniz.
3. Verileri ürün kategorisine göre gruplandırarak toplam satış miktarını hesaplayacaksınız.
4. Farklı veri setlerini (örneğin, müşteri bilgileriyle satış verilerini) birleştireceksiniz.

Adım 1 :

Verinin hazırlanmasının ardından “Excel Reader” node'u kullanılarak veri çalışmaya hazırlanır.


Row ID	I ProductID	S Product...	S Category	S SalesDate	I SalesA...	I Custom...
Row0	101	Laptop	Electronics	2024-01-10	1200	1
Row1	102	Smartphone	Electronics	2024-02-15	800	2
Row2	103	Tablet	Electronics	2024-03-20	400	3
Row3	104	Headphones	Accessories	2024-01-25	100	4
Row4	105	Camera	Electronics	2024-02-28	600	?
Row5	106	Monitor	Accessories	2024-03-10	200	5
Row6	107	Keyboard	Accessories	2024-04-05	50	6

Görsel 34

Görsel 34 gerekli proje için hazırlanan veridir.

Adım 2:

Duruma göre ideal bir filtreleme node'u kullanarak ilgili data filtrelenir. Sadece “Electronics” ürünlerinin filtrelenmesini talep edelim.



Görsel 35

Öncelikle kullanılması gereken filtre yöntemi “Row” Filtresidir. Kararı verdikten sonra “Configuration” sekmesine girilerek ilgili ayarlamalar yapılır. İlgili ayarlamalar yapıldıktan sonra verinin çıktısı mutlaka kontrol edilmelidir.


RowID	ProductID Number (integer)	ProductName String	Category String	SalesDate String	SalesAmount Number (integer)	CustomerID Number (integer)
Row0	101	Laptop	Electronics	2024-01-10	1200	1
Row1	102	Smartphone	Electronics	2024-02-15	800	2
Row2	103	Tablet	Electronics	2024-03-20	400	3
Row4	105	Camera	Electronics	2024-02-28	600	?

Görsel 36

Doğru ve istenilen şekilde filtrelendiğini bu tablodan anlayabiliriz.

Adım 3:

Görsel 36 içerisinde görünen “Missing Value” alanı proje içerisinde bizlere hatalı sonuçlar verebilir. Bunu engellemek için o kısımla ilgili gerekli çalışmalar yapılmalıdır.



Görsel 37

Missing Value alanı bir Integer değer olduğu için ve bir “ID” olduğu için ilgili alan için Fix Value değeri girdim.


RowID	ProductID <i>Number (integer)</i>	ProductName <i>String</i>	Category <i>String</i>	SalesDate <i>String</i>	SalesAmount <i>Number (integer)</i>	CustomerID <i>Number (integer)</i>
Row0	101	Laptop	Electronics	2024-01-10	1200	1
Row1	102	Smartphone	Electronics	2024-02-15	800	2
Row2	103	Tablet	Electronics	2024-03-20	400	3
Row4	105	Camera	Electronics	2024-02-28	600	10

Görsel 38

Missing Value alanının bu şekilde çözümü bulunmuştur.

Adım 4:

Analiz için sadece gerekli kolonları (örneğin, tarih, kategori, satış miktarı) tutulacaktır. Bunun için “Column Filter” kullanılacaktır.




Bu şekilde filtrelendir.

RowID	Category <i>String</i>	SalesDate <i>String</i>	SalesAmount <i>Number (integer)</i>
Row0	Electronics	2024-01-10	1200
Row1	Electronics	2024-02-15	800
Row2	Electronics	2024-03-20	400
Row4	Electronics	2024-02-28	600

Adım 5:

Ürün kategorisine göre toplam satış miktarını ve ortalama satış fiyatını hesaplayacağım. Bunun için *Group By Node*’u kullanacağım.



Görsel 39

“Category” bağımsız olarak çalıştırıp geri kalanlar üzerinden toplama işlemi yaptım.

RowID	Category String	Sum(SalesAmount) Number (integer)
Row0	Electronics	3000

Adım 6:

Joiner nodu kullanılarak iki veri birleştirilecek.

Row ID	I Custom...	S Custom...	S Location
Row0	1	Alice	New York
Row1	2	Bob	Los Angeles
Row2	3	Charlie	Chicago
Row3	4	Diana	Houston
Row4	5	Edward	Phoenix
Row5	6	Fiona	Philadelphia

Görsel 40

Görsel 40 ve Görsel 34 Joiner nodu ile birleştirilir.

Top Input ('left' table)

Bottom Input ('right' table)

CustomerID

CustomerID

Ortak veriler birleştirilerek Joiner işlemi yapmaya çalışılır.

Birleştirme ve ortak satırların tek bir şekilde görünmesini sağlamak için gerekli ayarlamalar da yapılır

Compare values in join columns by ☒ value and type ☐ string representation ☐ making integer types compatible

Include in output

☒ Matching rows
☐ Left unmatched rows
☐ Right unmatched rows

Inner join


Output options

☒ Split join result into multiple tables (top = matching rows, middle = left unmatched rows, bottom = right unmatched rows)
☒ Merge join columns
☐ Hlliting enabled


Ardından ilgili data incelenir.

#	RowID	ProductID Number (integ...	ProductN... String	Category String	SalesDate String	SalesAmo... Number (integ...	CustomerID Number (integ...	Customer... String	Location String
1	Row...	101	Laptop	Electronics	2024-01-10	1200	1	Alice	New York
2	Row...	102	Smartphone	Electronics	2024-02-15	800	2	Bob	Los Angeles
3	Row...	103	Tablet	Electronics	2024-03-20	400	3	Charlie	Chicago
4	Row...	104	Headphones	Accessories	2024-01-25	100	4	Diana	Houston
5	Row...	106	Monitor	Accessories	2024-03-10	200	5	Edward	Phoenix
6	Row...	107	Keyboard	Accessories	2024-04-05	50	6	Fiona	Philadelphia

Görsel 41

CustomerID ile birleştirilerek ortak bir veri oluşturulur.

Böylece KNIME üzerindeki önemli node'lar örnekler ile öğrenilmiş olundu.



Çalışma – 5 Ait KNIME üzerindeki akış görselidir.

Veri Bilimi Yöntemleri


Veri bilimi projelerinde sıkça kullanılan üç temel yöntem bulunmaktadır:

- SEMMA
- CRISP-DM
- KDD

Bu yöntemler, bir veri bilimi projesini yönetmek ve doğru bir yol haritası oluşturmak için rehberlik eder. Bir veri bilimi projesinde hangi noktadan başlanacağı, hangi adımların izleneceği ve projenin nasıl sonuçlandırılacağı, bu yöntemler sayesinde net bir şekilde planlanabilir. Bu soruların yanıtlanması ve projenin başlangıcından sonuna kadar adım adım planlanması, projenin başarısı için kritik bir öneme sahiptir.

SEMMA Yöntemi

SEMMA, **S**ample (Örnekleme), **E**xplore (Keşfetme), **M**odify (Değiştirme), **M**odel (Modelleme) ve **E**valuate (Değerlendirme) adımlarından oluşur. Veri hazırlığından model oluşturma ve değerlendirmeye kadar bir iş akışı sunar.




Görsel 42

Görsel 42 incelendiğinde, SEMMA modelinin örnekleme işlemiyle başladığı görülmektedir. Ancak, her projede örnekleme işlemiyle başlanması aynı verimi sağlamayabilir. Bu durum, projenin özelliklerine ve veri yapısına bağlı olarak değişiklik gösterebilir.

CRISP-DM Yöntemi

Cross Industry Standard Process for Data Mining, veri bilimi projelerinde en yaygın kullanılan yöntemdir ve şu altı aşamayı içerir:

1. **İş Probleminin Anlaşılması (Business Understanding):**
Projenin hedeflerini ve iş gereksinimlerini belirleyin. Çözülmesi gereken iş problemini net bir şekilde tanımlayın.
2. **Veri Anlama (Data Understanding):**
Veriyi toplayın, kalite kontrolü yapın ve veriden anlam çıkarın. Eksik veya hatalı verileri tespit edin.
3. **Veri Hazırlığı (Data Preparation):**
Analiz için veriyi temizleyin, dönüştürün ve uygun formatta hazırlayın. Bu aşama, zamanın büyük bir kısmını kapsar.
4. **Modelleme (Modeling):**
Farklı algoritmalar deneyerek veriden öğrenme modelleri oluşturun. Model parametrelerini optimize edin.
5. **Değerlendirme (Evaluation):**
Modelin iş hedeflerine uygun olup olmadığını kontrol edin. Modelin doğruluğunu ve performansını ölçün.
6. **Dağıtım (Deployment):**
Modeli gerçek hayatta kullanıma alın. Sonuçları paylaşın ve uygulamaya geçirilecek aksiyonları belirleyin.




Görsel 43

Görsel 43 incelendiğinde, CRISP-DM yöntemi görselidir. Öncelikle bir problem belirlenir ve probleme göre veriler çıkarılır. SEMMA modelinden ayrılan aşaması bu aşamadır. Ardından probleme göre oluşturulan verilerin analiz aşaması başlar ve elde edilen veriler ayıklanır. Temiz ve sağlıklı bir veri elde edildikten sonra Machine Learning Algoritması veya diğer modelleme yöntemleri ile modelleme yapılabilir. Ardından yapılan işlemin test süreci başlar ve yapılan modelleme veriye göre mi veya doğru bir sonuç alınıyor mu kontrol edilir. Eğer doğru bir işlem mevcutsa proje canlıya alınabilir. Fakat test esnasında çıkabilecek büyük hatalar varsa en başa dönülerek işlem tekrar edilir. En kullanışlı Veri Bilimi Yöntemi budur. Çoğu projede verimli bir şekilde kullanılmıştır.

KDD Yöntemi

KDD (Knowledge Discovery in Databases), veriden bilgi çıkarma sürecidir. Seçim, Ön işleme, Dönüştürme, Veri madenciliği ve Değerlendirme aşamalarından oluşur.

Bu yöntemler, veri bilimi projelerinde sistematik bir yol haritası sunarak, hem süreçlerin yönetilmesini kolaylaştırır hem de başarılı sonuçlara ulaşılmasını sağlar.



Görsel 44


Görsel 44 kullanılan yöntem, genellikle büyük araştırmalar gerektiren projeler için kullanılır ve bu tür projelerde çok daha büyük katkı sağlar. CRISPI – DM yönteminden farklı olarak bu aşamada verinin hazırlanması iki aşamada gerçekleşir.

Her yöntem neredeyse birbirine benzemektedir. Bunların kararlarını verebilmek için projeyi doğru anlamak ve ona göre bir yöntem izlemek önemlidir. Her proje içerisinde aynı yöntemin çalışması doğru bir yaklaşım değildir.

Analitik Seviyeleri

Problem çözme yetenekleri edinmek için bu adımlar oldukça önem arz etmektedir.

Analitik seviyeler, bir organizasyonun veriyi nasıl kullandığını ve hangi tür içgörüler elde ettiğini gösteren farklı aşamalardır. Bu seviyeler, organizasyonların karar verme süreçlerinde analitiği nasıl uyguladıklarını sistematik bir şekilde anlamalarına yardımcı olur. İşte yaygın olarak kullanılan analitik seviyeler:




KNIME ÜZERİNDEN DOSYA DÖNÜŞTÜRME

KNIME, farklı dosya tiplerini ve veri formatlarını dönüştürmek için güçlü araçlar sunar. Bu işlemleri gerçekleştirmek için aşağıdaki "Reader" nodelarını kullanabilirsiniz:


- **CSV Reader:** CSV dosyalarını okumak için kullanılır. Kolon ayracı (delimiter) gibi özellikler ayarlanabilir.
- **Line Reader:** Satır bazlı veriler üzerinde işlem yapmak için uygundur. Genellikle serbest metin veya yapılandırılmamış veriler için kullanılır.
- **Table Reader:** KNIME formatındaki tabloları (table files) okumak için tasarlanmıştır.
- **PMML Reader:** PMML formatında saklanan makine öğrenimi modellerini içeri almak için kullanılır.

Bu nodelar, farklı dosya türlerini okumak için kullanılır ve dönüştürme işlemleri sırasında birbirleriyle bağlanmaları gerekmektedir. Her bir node, belirli bir formatı işlemek için tasarlanmıştır ve dönüştürme sürecinde uyumlu node'larla entegre şekilde çalışır.

Örnek verilecek olursa, Excel formatında olan bir veriyi, CSV formatına çevirelim. Bunun için öncelikle "Excel Reader" nodu'nu ilgili çalışma ekranına yerleştirmemiz gerekmektedir.




Ardından “CSV Reader” nodu’nu da ilgili çalışma ekranına yanyana gelecek şekilde yerleştirilir.



“Excel Reader” nodu’na ilgili veri yüklenir ve “ARFF Writer” nodu ile birleştirilir ve gerekli configurationlar yapılır.

İlgili “Configuration” sayfasında belirli işlemler yapılarak istenilen formatta çevrilecektir.



MetaNode Yapısı

MetaNode, KNIME'da birden fazla düğümü bir araya getirip tek bir düğüm gibi kullanmamızı sağlar. Özellikle iş akışı karmaşıktığında, bu yapı işleri düzenlemek ve görsel olarak daha anlaşılır hale getirmek için çok kullanışlıdır.

Örneğin, bir veri temizleme sürecini MetaNode içine alıp, büyük bir iş akışını daha sade bir hale getirebilirsiniz. Ayrıca, oluşturduğunuz bir MetaNode'u başka projelerde de tekrar kullanabilirsiniz. Bunun için düğümleri seçip sağ tıklayarak "Collapse into MetaNode" seçeneğini seçmeniz yeterlidir.

KNIME Değişkenleri ve Değişken Akışı (Flow Variables)

Flow Variables, KNIME iş akışındaki parametreleri dinamik olarak kontrol etmenizi sağlar. Örneğin, bir filtreleme işlemini dışarıdan bir değişkenle belirleyebilir ya da bir döngü içinde sürekli değişen bir parametre kullanabilirsiniz. Bu, özellikle büyük projelerde hem kontrolü kolaylaştırır hem de iş akışını daha esnek hale getirir. Flow Variables'ı, düğümlerin ayarlarında bulunan "Flow Variables" sekmesinden ekleyebilir veya "Variable Creator" düğümü ile kendiniz oluşturabilirsiniz.

Örneğin, tarih aralığına bağlı olarak bir veri setini filtrelemek istiyorsanız, bu yöntemi kullanabilirsiniz.

Döngüler (Loops) ve Model Parametrelerinin Test Edilmesi ve İyileştirilmesi

Döngüler, KNIME'da aynı işlemi tekrar tekrar yapmak için kullanılır. Örneğin, bir modelin farklı parametrelerle çalıştırılarak en iyi kombinasyonun bulunması için döngüler kullanılabilir. Bunun için "Parameter Optimization Loop" gibi düğümler tercih edilir. Ayrıca, veri parçalarını ayrı ayrı işlemek ya da bir işlemi farklı veri setlerinde uygulamak için de döngüler kullanılabilir.

Örneğin, bir sınıflandırma modelinde parametrelerin en iyi değerlerini bulmak için bu yöntem oldukça etkilidir. Döngüleri başlatmak ve bitirmek için "Loop Start" ve "Loop End" düğümleri kullanılır.

Makine Öğrenmesi Modelleri

Makine öğrenmesi modellerinde, veriler genellikle üç gruba ayrılarak çalışılır: **eğitim kümesi**, **doğrulama kümesi** ve **test kümesi**.

Eğitim kümesi, modelin öğrenmesi için kullanılır. Model burada verilerdeki örüntüleri ve ilişkileri öğrenir. Ancak modelin bu veriyi sadece ezberlemesi değil, genelleme yapabilmesi gerekir. Yani eğitim kümesi üzerindeki başarı, modelin gerçek dünyada nasıl performans göstereceğini garanti etmez.

Doğrulama kümesi, modeli eğitirken parametreleri ayarlamak için kullanılır. Mesela, bir modelde kaç katman kullanılacağı ya da bir hiperparametrenin değeri doğrulama kümesindeki performansa göre belirlenebilir.

Test kümesi ise tamamen modelin yeni verilerle nasıl başa çıktığını görmek için kullanılır. Test kümesi modeli değerlendirmek için en kritik adımlardan biridir çünkü bu veriler modelin hiç görmediği verilerdir.

Overfitting (Ezberleme)

Ezberleme ya da overfitting, modelin eğitim kümesindeki verilere çok iyi uyum sağlaması, hatta fazlasıyla uyum sağlaması ama yeni verilerde (örneğin test kümesinde) kötü performans göstermesi durumudur. Bu, eğitim kümesindeki küçük detaylara ya da gürültülere bile odaklanmasından kaynaklanır. Model adeta "ezberler" ama genelleyemez.

Örnek: Diyelim ki bir model, eğitim verilerindeki her bir örneği mükemmel bir şekilde sınıflandırıyor. Ancak aynı model, test kümesinde yeni verilerle karşılaştığında düşük bir doğruluk oranına sahip. Bu durumda overfitting var diyebiliriz.

Overfitting Önlenebilir mi?

Daha Fazla Veri Kullanmak:

- Modelin genelleme yapmasını kolaylaştırır. Daha fazla veri her zaman kolay bulunmasa da, veri artırma (örneğin görüntülerde döndürme, ölçekleme gibi) yöntemleri kullanılabilir.

Modeli Basitleştirmek:

- Karmaşık modeller, eğitim verisine fazlasıyla uyum sağlayabilir. Daha sade bir model seçmek, genelleme kabiliyetini artırabilir.

Düzenleme (Regularization):

- Modellerde bazı tekniklerle aşırı öğrenmeyi engelleyebilirsiniz. Örneğin, sinir ağlarında "dropout" kullanmak veya L1/L2 düzenleme yöntemleri uygulamak etkili bir çözüm olabilir.

Erken Durdurma:

- Model eğitimi sırasında doğrulama kümesindeki başarı izlenir. Eğer model doğrulama kümesinde kötüleşmeye başlarsa eğitim süreci durdurulur.

K-atlamalı Doğrulama:

- Veri setini farklı parçalara bölerek modelin her parça üzerinde test edilmesini sağlamak. Bu yöntem, modelin genelleme yeteneğini daha iyi anlamamıza yardımcı olur.

Test ve Eğitim Verilerini Karıştırmamak:

- Bu iki veri kümesinin kesinlikle birbirinden bağımsız olması gerekir. Eğitimde kullanılan verilerle test yapmak modelin gerçek performansını yanıltır.

Makine öğrenmesinde temel amaç, modelin sadece mevcut veriyi öğrenmesi değil, yeni ve görülmemiş veriler üzerinde de iyi sonuçlar verebilmesidir. Eğer model overfitting yaparsa, gerçek dünya uygulamalarında başarısız olabilir. Bu yüzden eğitim sürecinde yukarıdaki yöntemleri uygulamak oldukça önemlidir.

Naive Bayes Yöntemi

Naive Bayes, olasılıklara dayalı bir sınıflandırma algoritmasıdır. Bayes Teoremi'ne dayanır ve "naive" (saf) adını, özellikler arasında bağımsızlık varsayımında bulunmasından alır. Yani, bir veri kümesindeki her bir özelliğin diğer özelliklerden bağımsız olduğunu varsayar.

Bayes Teoremi:

Bayes Teoremi şu şekilde ifade edilir:

$$P(A|B) = \frac{P(B|A) * P(A)}{P(B)}$$

- **P(A|B):** B gerçekleştiğinde A'nın olasılığı (Posterior Olasılık)
- **P(B|A):** A gerçekleştiğinde B'nin olasılığı (Likelihood)
- **P(A):** A'nın genel olasılığı (Prior)
- **P(B):** B'nin genel olasılığı (Evidence)

Naive Bayes, bu teoremi kullanarak bir sınıfa ait olma olasılığını hesaplar.

Naive Bayes Hangi Verilerde Kullanılır

Naive Bayes, hızlı ve etkili bir sınıflandırıcı olduğu için çeşitli veri bilimi projelerinde kullanılır. Bazı kullanım alanları şunlardır:

1. Metin Sınıflandırma (Text Classification):

- E-posta filtrelemesi: E-postaları spam ya da spam değil olarak sınıflandırır.
- Duygu analizi: Bir metnin olumlu ya da olumsuz bir duygu içerdiğini belirler.

2. Tahmin ve Öngörüler:

- Naive Bayes, veri setindeki geçmiş verilere dayanarak yeni verilere tahminlerde bulunur. Örneğin, bir kullanıcının belirli bir ürünü satın alıp almayacağını tahmin etmek için kullanılabilir.

3. Sağlık ve Tıp Uygulamaları:

- Hastalık teşhisi: Hastanın belirtilerine göre bir hastalığa sahip olma olasılığını hesaplar.

4. Sahtecilik Tespiti:

- Naive Bayes, finansal işlemler gibi alanlarda sahtekarlığı tespit etmek için kullanılabilir.

5. Görüntü İşleme:

- Görüntülerde belirli nesneleri sınıflandırmak ya da tanımak için kullanılabilir.

Naive Bayes'in Avantajları

- **Hızlı ve Basit:** Özellikle büyük veri setleri üzerinde hızlı bir şekilde çalışır.
- **Az Veride İyi Performans:** Küçük veri setlerinde bile etkili sonuçlar verebilir.
- **Kolay Yorumlanabilir:** Sonuçları anlamak ve yorumlamak kolaydır.

Naive Bayes'in Dezavantajları


- **Bağımsızlık Varsayımı:** Özelliklerin bağımsız olmadığı durumlarda performansı düşebilir.
- **Sürekli Veriler:** Sürekli özelliklerin olasılıklarını hesaplamak için ek dönüşümler gerekebilir (örneğin, Gauss Naive Bayes kullanımı).

Naive Bayes Çalışması

Çalışma Konusu: Boy kilo Cinsiyet tablosu üzerinden makine eğitilip doğru cinsiyeti tahmin etmesini isteyeceğiz.

Adım 1: Veri tablosu hazırlanır.

Adım 2: Veriler “Partitioning” node’u olarak ikiye bölünür böylece eğitim ve test datası kendiliğinden oluşmuş olur. Configuration sayfası aşağıdaki gibidir.




Adım 3: Naive Bayes teoremini kullanabilmek için iki adet node mevcuttur. “*Naive Bayes Learner*” ve “*Naive Bayes Predictor*”. Çıkan sonucunun aşağıda gözlemleyebiliriz.

#	RowID	BOY Number (integer)	KİLO Number (integer)	CİNSİYET String	Prediction (CİNSİYET) String
1	Row0	185	85	Erkek	Erkek
2	Row4	175	80	Erkek	Kadın
3	Row6	169	75	Erkek	Kadın
4	Row8	180	80	Erkek	Erkek
5	Row...	162	97	Erkek	Kadın
6	Row...	180	85	Kadın	Erkek


Not: Veri az olduğu için gözle tarama yapılabilir fakat daha büyük verilerle çalışıldığında gözle karar vermek doğru bir sonuç doğurmaz. **Bu sebeple “Score” node’u kullanarak daha doğru sonuç alınabilir.**

Score nodunun configuration alanı aşağıdaki gibidir




#	RowID	Erkek Number (integer)	Kadın Number (integer)
1	Erkek	2	3
2	Kadın	1	0

Bu sayede gözle veri taramak yerine daha hızlı sonuç alıp yüzde kaçının kullanılabilir olduğunu gözlemleyebiliriz.



Görsel 45

Görsel 45 ilgili çalışmanın KNIME üzerinde oluşturulmuş halidir.

Numeric Binner, sayısal değerleri belirli aralıklarla böler ve her aralığı bir kategoriye dönüştürür. Örneğin, bir yaş sütununu belirli yaş gruplarına ayırmak için kullanılabilir. Bir çok daha oluşturulabilir.

Decision Tree Öğrenmesi

Makine öğrenmesinde kullanılan bir sınıflandırma ve regresyon algoritmasıdır. Veri setindeki özelliklere dayalı olarak kararlar veren ve sonuçları tahmin eden bir modeldir. Adı, görsel yapısının bir ağaç şeklinde olması nedeniyle bu şekilde anılır.

Decision Tree'nin Avantajları

- **Kolay Yorumlanabilir:** Ağacın yapısı, insanlar tarafından kolayca anlaşılabilir.
- **Esnek:** Hem sınıflandırma hem de regresyon problemlerinde kullanılabilir.
- **Özellik Ölçeklendirme Gerektirmez:** Verinin normalizasyonuna veya standartlaştırılmasına gerek yoktur.
- **Hızlı ve Verimli:** Küçük veri setlerinde hızlı bir şekilde çalışır.

Decision Tree'nin Dezavantajları


- **Overfitting (Ezberleme):**
 - Çok derin ağaçlar, eğitim verisine fazla uyum sağlar ve genelleme yeteneği zayıflar.
 - Çözüm: Ağaç derinliğini sınırlamak veya düzenleme (pruning) yöntemlerini kullanmak.
- **Kararsızlık:**
 - Küçük veri değişiklikleri bile ağacın yapısını tamamen değiştirebilir.
- **Büyük Veri Setlerinde Performans Sorunları:**
 - Çok fazla veri olduğunda performans düşebilir.

Decision Tree Çalışması

Çalışma Konusu: Boy kilo Cinsiyet tablosu üzerinden makine eğitilip doğru cinsiyeti tahmin etmesini isteyeceğiz.

Adım 1: Veri tablosu hazırlanır.

Adım 2: Veriler “Partitioning” node’u olarak ikiye bölünür böylece eğitim ve test datası kendiliğinden oluşmuş olur. Configuration sayfası aşağıdaki gibidir.



Adım 3: Decision Tree teoremini kullanabilmek için iki adet node mevcuttur. “Decision Tree Predictor” ve “Decision Tree Training” Çıkan sonucunun aşağıda gözlemleyebiliriz.

Decision Tree sınıflandırma için kullanılan bir yöntem olduğu için o kısımlar dikkatli bir şekilde yapılmalıdır.

Dialog - 6:42 - Decision Tree Learner

File

Options PMMLSettings Flow Variables Job Manager Selection

General

Class column CİNSİYET

Quality measure

Pruning method

☒ Reduced Error Pruning

Min number records per node

Number records to store for view

☒ Average split point

Number threads

☒ Skip nominal columns without domain information

Root split

☐ Force root split column

Root split column KİLO

Binary nominal splits


☐ Binary nominal splits

Max #nominal

☐ Filter invalid attribute values in child nodes

OK Apply Cancel ?


Sınıflandırma içerisinde çalışan bir algoritma olduğu için "Cinsiyet" sınıflandırması yapılabilir ve daha sonra diğer işlemler de ayarlanmalıdır



Desicion Tree içerisinde yer alan kısmın tahmin olasılıkları yukarıdaki gibidir.


Not: Veri az olduğu için gözle tarama yapılabilir fakat daha büyük verilerle çalışıldığında gözle karar vermek doğru bir sonuç doğurmaz. **Bu sebeple “Score” node’u kullanarak daha doğru sonuç alınabilir.**

Score nodunun configuration alanı aşağıdaki gibidir



#	RowID	Erkek Number (integer)	Kadın Number (integer)
1	Erkek	1	3
2	Kadın	2	0

Bu sayede gözle veri taramak yerine daha hızlı sonuç alıp yüzde kaçının kullanılabilir olduğunu gözlemleyebiliriz.



Görsel 46

Görsel 46 ilgili çalışmanın KNIME üzerinde oluşturulmuş halidir.

Not: Aynı problem üzerinde 2 farklı algoritmanın kullanılması karşılaştırma yapmak için çok verimli bir yöntemdir. Problemden probleme ilgili algoritmalar farklılık göstereceğinden dolayı doğru kararı verebilmek için doğru yöntemlerden biridir.

Decision Tree View kullanarak da görselleştirme işlemi yapılabilir

Birliktelik Kural Çıkarımı (Association Rule Mining)

Birliktelik kural çıkarımı, verilerdeki öğeler arasında ilişki veya kalıpları keşfetmek için kullanılan bir veri madenciliği tekniğidir. Özellikle perakende, pazarlama ve öneri sistemlerinde yaygın olarak kullanılır. Amaç, bir veri setinde bir arada bulunan öğeler arasındaki kuralları bulmaktır.

Algoritmalar

1. Apriori Algoritması:

- En sık kullanılan algoritmalarından biridir.
- Verileri tarayarak sık geçen öğe gruplarını bulur.
- Aşamalar:
 1. Minimum destek seviyesini karşılayan öğeleri belirler.
 2. Daha büyük öğe gruplarını oluşturur ve minimum destekle eşleşenleri tutar.

2. FP-Growth Algoritması:

- Apriori algoritmasına göre daha hızlıdır.
- Verileri bir "frekans tabanlı ağaç" yapısında saklar ve sık geçen öğeleri daha verimli bul

Kümeleme, Clustering ve K-Means Algoritmaları – Çalışması


Çalışma Konusu : Belirli bir veri üzerinden belirli algoritmaları kullanarak çalışma prensibini anlamak

Adım 1: Veriyi oluşturmak (Her Seviyeye Uygun Uçtan Uca Veri Bilimi, KNIME ile eğitiminden alınmıştır.).

Verimiz yaprak cinsileri ile alakalı bir veridir.

Adım 2: Veri için KNIME hazırlanır.


Algoritma tarafından eğitileceği için öncelikle “Test” ve “Eğitim” olmak üzere ayarlanır. “Configuration” içerisinde bazı ayarlamalar yapılmalıdır.



%70 ve Draw randomly olarak ayarlanır.


K-Means Algoritması kullanımı:

K-mean algoritması orta nokta bularak işlem yapar.




Daha doğru bir sonuç görebilmek için bir sonuç node'u eklenmesi gerekmektedir.

“Scatter Plot” kullanılarak işlem yapılabilir.




Görsel 47

Görsel 47 içerisinde net ayrışmayı gözlemleyebiliriz.



Bu verileri renklendirerek de gözlemleyebiliriz. Bunun için “Color Manager” kullanıp daha sonra “Scatter Plot” node’si kullanıldığında işlem daha anlaşılır olabilir.



Doğrusal (Linear) Regresyon


Doğrusal regresyon, bağımlı bir değişken (çıktı, hedef) ile bir veya birden fazla bağımsız değişken (girdiler) arasındaki doğrusal ilişkiyi modellemek için kullanılan bir istatistiksel yöntemdir.

- **Tahmin:** Gelecekteki değerleri öngörmek için bir model kullanma sürecidir.
- **Doğrusal regresyon:** Veriler arasındaki doğrusal ilişkileri modellemek için kullanılan bir yöntemdir.
- **Uygulama:** Python'da **Sklearn** kütüphanesi ile doğrusal regresyon oldukça kolay yapılabilir. Doğru tahminler için verilerin temiz ve modelin değerlendirilmiş olması önemlidir.

Prediction ve Linear Regression Çalışması:

Çalışma Konusu:

Veri her zaman önemlidir. Çünkü doğru sonuç çıkması için verinin her zaman doğru olması gerekmektedir. Boyları kullanarak -> kiloları öğrenmek (Linear) oluşturulabilir mi ?



İlgili kısmın sonucundaki elde edilen tabloda doğrusal bir geçiş mevcuttur.

1. K-Katlama Çapraz Doğrulama (K-Fold Cross-Validation)

Nedir?

Bir modeli değerlendirmek için kullanılan bir yöntemdir. Veriyi **K** eşit parçaya böler ve her bir parça bir kez doğrulama verisi olarak, kalan parçalar ise eğitim verisi olarak kullanılır. Bu işlem, her bir parça doğrulama verisi olacak şekilde toplam **K** kez tekrarlanır.

Nasıl Çalışır?

- Veri seti, **K** alt gruba (fold) ayrılır.
- Model, **K-1** fold üzerinde eğitilir ve kalan fold üzerinde test edilir.
- Bu işlem **K** kez yapılır ve her bir iterasyonun doğruluk ölçütü kaydedilir.
- Sonuçta, tüm katlamaların ortalama doğruluğu hesaplanır.

Avantajları:

- Veri setini daha verimli kullanır.
- Modelin genelleştirme başarısını daha iyi ölçer.

2. Confusion Matrix (Karmaşıklık Matrisi)

Nedir?

Sınıflandırma modelinin performansını değerlendirmek için kullanılan bir tablodur. Tahmin edilen sonuçlarla gerçek sonuçları karşılaştırır.

	Gerçek Pozitif (P)	Gerçek Negatif (N)
Tahmin Pozitif (P')	True Positive (TP)	False Positive (FP)
Tahmin Negatif (N')	False Negative (FN)	True Negative (TN)

Bileşenler:

- **True Positive (TP):** Modelin doğru şekilde pozitif olarak tahmin ettiği örnekler.
- **False Positive (FP):** Gerçekte negatif olan, ancak modelin pozitif olarak tahmin ettiği örnekler (Type I Error).
- **True Negative (TN):** Modelin doğru şekilde negatif olarak tahmin ettiği örnekler.
- **False Negative (FN):** Gerçekte pozitif olan, ancak modelin negatif olarak tahmin ettiği örnekler (Type II Error).

3. Precision, Recall, Sensitivity, Specificity

- **Precision (Kesinlik):**
Modelin pozitif tahminlerinin ne kadarının doğru olduğunu ölçer.
- **Recall (Duyarlılık veya Sensitivity):**
Gerçek pozitif örneklerin ne kadarının doğru tahmin edildiğini ölçer.
- **Specificity (Özgüllük):**
Gerçek negatif örneklerin ne kadarının doğru tahmin edildiğini ölçer.
- **F1-Score:**
Precision ve Recall'un harmonik ortalamasıdır, dengeli bir performans ölçütüdür.

4. Kümeleme Saflığı (Clustering Purity)

Nedir?

Kümeleme algoritmalarının performansını ölçmek için kullanılan bir metriktir. Bir kümedeki verilerin doğru sınıfa ne kadar iyi oturduğunu gösterir.

Hesaplama:

- Her bir kümenin en sık görülen sınıfına ait öğelerin sayısı bulunur.
- Bu sayılar toplanır ve toplam veri sayısına bölünür.

Özellikler:

- Saflık 1'e ne kadar yakınsa, kümeleme o kadar iyidir.

- Dezavantaj: Kümeleme sayısının artmasıyla saflık genellikle yükselir.

KNIME Üzerinde Kullanılabilecek Diller

Python Bağlantısı

- **Python Integration:**
KNIME, Python ile veri işleme ve analiz için **Python Script** düğümleri sunar.
 - **Python düğümleri:** Veri manipülasyonu, model eğitimi ve özelleştirilmiş algoritmalar için kullanılır.
 - **Nasıl çalışır:**
 1. **KNIME Ayarları > Python Integration** bölümünden Python ortamını tanımlayın.
 2. Python Script düğümünü iş akışına ekleyin.
 3. Python kodunuzu bu düğümde yazabilirsiniz.

R Bağlantısı

- **R Integration:**
R dilini kullanmak için KNIME, **R Snippet** ve **R View** düğümleri sunar.
 - **Nasıl çalışır:**
 1. **KNIME Ayarları > R Integration** üzerinden R ortamını kurun.
 2. R Snippet düğümünü ekleyin ve kodunuzu yazın.
 3. Veri giriş ve çıkışını KNIME ile entegre edin.

Java Bağlantısı

KNIME, Java diline özel genişletilebilirliği ile bilinir.

- **Java Snippet Node:**
 - Basit Java kodu yazmak için kullanılır.
 - Örneğin, özelleştirilmiş bir hesaplama veya veri işleme işlemi yapmak için kullanılabilir.
- **Java IF Switch:**
 - Akış kontrolü için Java dilini kullanarak karar mekanizmaları oluşturabilirsiniz.

Ensemble Yöntemleri ve Meta Öğrenme Algoritmaları

Ensemble yöntemleri, birden fazla makine öğrenimi modelini bir araya getirerek tahmin doğruluğunu artırmayı hedefler. Meta öğrenme algoritmaları (Meta Learner), bu yöntemlerin bir parçası olarak, farklı modellerin çıktısını birleştirerek nihai tahmin sürecini yönetir. Bu bağlamda incelenen temel yöntemler şunlardır:

1. **Bagging (Bootstrap Aggregating):**
Bagging, varyansı azaltmak ve overfitting'i önlemek amacıyla kullanılan bir

yöntemdir. Eğitim verisi üzerinde bootstrap yöntemiyle rastgele alt veri setleri oluşturulur ve her alt veri seti üzerinde bağımsız modeller eğitilir. Nihai tahmin, bu modellerin çıktılarının birleştirilmesiyle yapılır.

Örnek: **Random Forest**.

2. **Boosting:**

Boosting, modellerin ardışık olarak eğitildiği bir yöntemdir. Her bir model, bir önceki modelin yaptığı hataları dikkate alarak eğitilir ve bu süreç tekrarlanır. Sonuçlar ağırlıklı birleştirme yöntemiyle değerlendirilir.


Örnekler: **AdaBoost, Gradient Boosting, XGBoost**.

3. **Fusion (Model Birleştirme):**

Farklı model türlerinin bir araya getirilmesiyle oluşturulan bir yöntemdir. Çeşitli modeller, aynı veri üzerinde eğitilir ve çıktıları birleştirilerek daha güçlü bir tahmin modeli elde edilir.

Bu yöntemler, son yılların en etkili ve verimli makine öğrenmesi algoritmaları arasında yer almaktadır. Özellikle güncel projelerimizden birinde kullandığımız Random Forest algoritması, yüksek performansı ile öne çıkarak başarılı ve etkili projeler geliştirmemize olanak tanımıştır.

Çalışma – MAVL ve Prediction Fusion Uygulaması




Naive bayes'den gelen sonuç 96.67% ile, prediction fusion'dan gelen 96.67% ile, SVM'den gelenin ise 93.333% ile accuracy'e sahip olduğunu göstermektedir. Naive bayse 96.67% olduğu için prediction'da değerini ondan almaktadır.

Çalışma – Random Forest Uygulaması


Çalışma Konusu: Random Forest uygulaması Iris veri setini kullanarak öğrenmek

Adım 1: Excel Reader ve Partitioning kullanarak işleme başlanır. Partitioning node'u için "Configuration" düzenlenmelidir.




Veri set 80% ve 20% olarak ikiye bölünmüştür.

Adım 2: KNIME üzerinden node'lar birleştirilerek işleme hazılanır.




Random Forest Learner ve Random Forest Predictor kullanılarak bu makine öğrenmesi modülü oluşturulur. Şu an görselde kırmızı olduğu için "Configuration" düzenlenmelidir.



İlgili ayarlamalar bu şekilde bırakılmıştır.

Adım 3: Ayarlamalar tamamlanır ve modülün çalışması beklenir.



Score sonucuna göre işlemin durumu anlaşılabilir. Program çalıştırıldıktan sonra elde edilen confusion matrix'i göstermektedir. Accuracy 93.3% gelmiştir.

Derin Öğrenme

Derin öğrenme, insan beynindeki sinir ağlarının çalışma prensibini taklit eden yapay sinir ağları (Artificial Neural Networks) üzerine kurulu bir makine öğrenmesi alt dalıdır.

Büyük miktarda veriyi işleyip anlamlı kalıplar ve özellikler çıkarmak için çok katmanlı sinir ağları kullanır.

Özellikle görüntü tanıma, ses işleme, doğal dil işleme gibi karmaşık problemler üzerinde oldukça başarılıdır. Derin öğrenme, büyük veri setleri ve güçlü hesaplama kaynakları ile çalışır ve kendine özgü özellikleri otomatik olarak öğrenebilir. **Bu, manuel özellik mühendisliği ihtiyacını azaltır ve daha doğru tahminler sağlar.**

